

武汉大学2026版

实验二：降维及聚类

授课老师：郭迟 教授

guochi@whu.edu.cn

武汉大学机器人学院

2026.3

武汉大学2026版

- 1 前期准备工作
- 2 实验内容要求
- 3 实验报告要求

1 Python



- Python是当前最流行的机器学习语言，有大量的开源资源以供下载
- 为了更好的调试和运行代码
 - 运行环境和工具包的下载与安装使用Anaconda进行管理
 - 代码使用Pycharm进行编译和运行
- Python推荐版本号3.7以上

2

Anaconda



- Anaconda是Python的包管理器和环境管理器，附带了一大批常用数据科学包，它附带了conda、Python和 150 多个科学包及其依赖项
- Anaconda推荐版本号5.0.0以上

3 Pycharm



- PyCharm是一种常用的Python IDE，带有一整套可以帮助用户在使用Python语言开发时提高其效率的工具，比如调试、语法高亮、Project管理、代码跳转、智能提示、自动完成、单元测试、版本控制
- Pycharm推荐社区版本（Community）

- Anaconda+Pycharm+Python安装教程：

<https://cloud.tencent.com/developer/article/2125391>

4 Install Package



- 根据安装教程创建python环境，并在pycharm中新建本次实验项目
- 安装以下所需包

- **pip install numpy**



- NumPy(Numerical Python) 是 Python 语言的一个扩展程序库，支持大量的维度数组与矩阵运算，此外也针对数组运算提供大量的数学函数库

- **pip install matplotlib**



- Matplotlib 是 Python 中最受欢迎的数据可视化软件包之一，支持跨平台运行，它是 Python 常用的 2D 绘图库，同时它也提供了一部分 3D 绘图接口。
Matplotlib 通常与 NumPy、Pandas 一起使用，是数据分析中不可或缺的重要工具之一

4 Install Package



- 根据安装教程创建python环境，并在pycharm中新建本次实验项目
- 安装以下所需包

- **pip install scikit-learn**

- Scikit-learn 是一个非常知名的Python机器学习库，它广泛地用于统计分析和机器学习建模等数据科学领域。它具有如下特点：
 - 模型多：用户通过scikit-learn能够实现各种监督和非监督学习的模型
 - 功能多：进行数据的预处理、特征工程、数据集切分、模型评估等工作
 - 数据多：内置丰富的数据集，比如：泰坦尼克、鸢尾花等

5 Package调用




➤ 输入以下代码对Package进行调用

```
1. import numpy as np
2. from matplotlib import pyplot as plt # 作图
3. from mpl_toolkits.mplot3d import Axes3D # 3D作图
4. from sklearn.datasets import make_blobs # 聚类数据集生成
5. from sklearn.decomposition import PCA # PCA降维
6. from sklearn.cluster import KMeans # Kmeans模型
7. from sklearn.cluster import DBSCAN # DBSCAN模型
```


武汉大学2026版

- 1 前期准备工作
- 2 实验内容要求
- 3 实验报告要求

1 聚类方法



2 数据集生成

➤ 调用sklearn.datasets中的make_blobs方法生成数据集

```
1. X, y = make_blobs(  
    n_samples=500, # 样本个数  
    n_features=8, # 特征个数  
    centers=3, # 类别中心数目  
    cluster_std=4.0, # 类别标准差  
    random_state=3 # 随机种子)
```


3 特征降维

➤ 调用PCA降维

```
1. pca = PCA(n_components=3)
2. X_rd = pca.fit_transform(X)
```

➤ 数据集降维后的可视化

```
1. fig1 = plt.figure(figsize=(10, 8))
2. ax1 = Axes3D(fig1)
3. x1 = X_rd[:, 0]
4. x2 = X_rd[:, 1]
5. x3 = X_rd[:, 2]
6. ax1.scatter(x1, x2, x3, s=25, c='m', marker='p')
7. plt.show()
```



4 KMean聚类及可视化

- 调用sklearn.cluster中的Kmeans对降维后的数据集进行聚类

```
1. KMean_model = KMeans(n_cluster=3, # 聚类数目
                        init='random', # 随机初始向量
                        n_init=1) # 运行1次取最好结果
   .fit(X_rd)


2. y_predict = KMean_model.labels_ # 预测

3. clu_centers = KMean_model.cluster_centers_ # 聚类中心
```

4

KMean聚类及可视化

```
def plot_kmean_data3d(X, y, model):  
    centers = model.cluster_centers_  
    fig = plt.figure(figsize=(10, 8))  
    ax = Axes3D(fig)  
    class1 = np.where(y == 0) # 找到y=0的位置  
    class2 = np.where(y == 1) # 找到y=1的位置  
    class3 = np.where(y == 2) # 找到y=2的位置  
    ax.scatter(np.ravel(X[class1, 0]), np.ravel(X[class1, 1]), np.ravel(X[class1, 2]), s=25, c='r', marker='o')  
    ax.scatter(np.ravel(X[class2, 0]), np.ravel(X[class2, 1]), np.ravel(X[class2, 2]), s=25, c='g', marker='^')  
    ax.scatter(np.ravel(X[class3, 0]), np.ravel(X[class3, 1]), np.ravel(X[class3, 2]), s=25, c='b', marker='s')  
    ax.scatter(centers[:, 0], centers[:, 1], centers[:, 2], s=25, c='k', marker='x')  
    ax.legend(["y=0", "y=1", "y=2"])  
    ax.legend(["y=0", "y=1", "y=2", "Centers"])  
    ax.set_xlabel('X1')  
    ax.set_ylabel('X2')  
    ax.set_zlabel('X3')  
    plt.show()
```




➤ 调节聚类数目，观察并分析聚类结果

5 DBSCAN聚类及可视化

➤ 调用sklearn.cluster中的DBSCAN对降维后的数据集进行聚类

```
1. DBSCAN_model =  
    DBSCAN(eps=4,min_samples=10,metric='Euclidean').fit(X_rd)  
2. fig1 = plt.figure(figsize=(10, 8))  
3. ax1 = Axes3D(fig1)  
4. ax1.scatter(X_rd[:, 0], X_rd[:, 1],  
    X_rd[:, 2], c=DBSCAN_model.labels_  
5. plt.show()
```



➤ 调节eps和min_samples, 观察并分析聚类结果

6 聚类性能评估

外部指标

FM指数 Fowlkes and Mallows Index, FMI	$FMI = \sqrt{\frac{a}{a+b} \times \frac{a}{a+c}}$
Rand指数 Rand Index, RI	$RI = \frac{2(a+d)}{m(m-1)}$

上述指标的结果均在[0,1]区间，值**越大越好**

内部指标

DB指数 Davies-Bouldin Index, DBI	$DBI = \frac{1}{k} \sum_{i=1}^k \max_{j \neq i} \left(\frac{\text{avg}(C_i) + \text{avg}(C_j)}{d_{\text{cen}}(\mu_i, \mu_j)} \right)$
--------------------------------------	--

DB 指数**越小**就越就意味着簇内距离越小同时簇间距离越大，说明聚类的性能**越好**

6 聚类性能评估

- 调用 sklearn.metrics 中的 fowlkes_mallows_score, rand_score 和 davies_bouldin_score 方法

```
print('FMI's value :', fowlkes_mallows_score(y, y_predict))  
print('RI's value :', rand_score(y, y_predict))  
print('DB's value :', davies_bouldin_score(X_rd, y_predict))
```

武汉大学2026版

1 前期准备工作

2 实验内容要求

● 3 实验报告要求

1 报告要求

1. 实验要求和内容介绍
2. 数据集准备及划分
3. 模型介绍
4. 性能指标含义诠释
5. 模型实验结果对比和分析
6. 实验总结
7. 标题自拟。一级标题黑体3号加粗，正文宋体4号，要求排版美观，图表均需要有图名图号或表名表号
8. 代码要求进行注释
9. 统一打包报告和代码，命名：学号_姓名.rar



武汉大学

WUHAN UNIVERSITY

欢迎大家提问

QUESTIONS ARE INVITED

➤➤➤➤➤➤➤➤ 武汉大学数智教育实践创新平台



武汉大学《人工智能与机器学习》参考课件

© 郭迟 编著 (2026版)

各学院授课教师可自行删改课件内容

仅用于武汉大学课程教学，未经许可不得商用

网络媒体、慕课使用须经课程组授权